PDFuni – akcenty v PDF záložkách

Petr Olšák

Záložky v PDF dokumentu (outlines, bookmarks) jsou texty, které za jistých okolností zobrazují PDF prohlížeče a které jsou klikací: rozvírají se a nabízejí stromovou strukturu. A hlavně klik na text v záložce způsobí skok na tomu odpovídající místo v dokumentu. Záložky se nikdy netisknou. Mnozí uživatelé pdfTEXu si jistě všimli, že český nebo slovenský text má někdy sklon ke znehodnocení akcentovaných znaků, pokud jej posíláme do záložek. V tomto článku si vysvětlíme pozadí těchto problémů a popíšeme makro PDFuni pro plainTEX, které problém s českými a slovenskými texty v záložkách a dalších podobných místech řeší.

1 Kódovací standardy pro PDF stringy

PDF stringy jsou jednak texty v záložkách a dále texty v informaci o PDF dokumentu vložené příkazem \pdfinfo o autorovi, názvu díla, klíčových slovech a podobně. Údaje z \pdfinfo lze z dokumentu vydolovat programem pdfinfo na příkazovém řádku a některé PDF prohlížeče je také dokáží zobrazit.

PDF stringy nejsou součástí hlavního textu dokumentu, takže pro ně není použit font vybraný autorem dokumentu. Místo toho si PDF prohlížeč k zobrazení PDF stringů zavolá font, který je zrovna v době prohlížení po ruce a který mu nabídne operační systém.

Specifikace PDF formátu [1] vymezuje (v dodatku D) pro PDF stringy dvě možná kódování, První je jednobytové (tj. jeden znak je reprezentován jedním bytem) a jmenuje se PDFDocEncoding. Toto kódování se shoduje s viditelnými znaky z ISO-8859-1, takže západoevropané s ním nemají problémy. Nevýhodou tohoto kódování je, že v něm nenajdeme většinu akcentovaných znaků české a slovenské abecedy. Nestaráme-li se o nic jiného, je uložený string interpetován PDF prohlížečem jako kódovaný podle PDFDocEncoding, takže nám to zákonitě poničí české texty.

Kvůli tomu jsem se rozhodl do makra OPmac [2] zařadit konverzní proces, který veškeré české a slovenské akcentované znaky převede do jejich ASCII podobných znaků bez akcentu a teprve takto převedený text uloží jako PDF string. V záložkách pak sice nevidíme akcenty, ale taky tam nevidíme nesmysly, ke kterým to je náchylné. I kdyby byly PDF stringy správně kódované pro češtinu (jak popíšeme za chvíli), může se stát, že nejsou správně v prohlížeči zobrazeny, protože správné zobrazení navíc závisí na správném nastavení locales a na dalších systémových parametrech. Rozhodl jsem se tedy pro robustní řešení: PDF stringy generované makrem OPmac budou jenom v ASCII. A nehodlám to měnit.

Nicméně uživatelé např. balíčku hyperref si jistě všimli, že za jistých příznivých okolností konstelace hvězd (tj. hyperref pracuje v UNICODE a PDF prohlížeč má správně nastaveny veškeré systémové parametry) dokáží vygenerovat nezmršené české texty i v záložkách. Je to tím, že PDF specifikace nabízí druhou (a poslední) možnost kódování PDF stringů, kterou nazývá UTF-16BE Unicode (dále jen UNICODE). Kódování PDF stringu v tomto režimu se pozná tak, že první dva byty stringu mají hodnotu 254, 255. Je to prefix pro přepnutí do tohoto kódování. Podrobněji viz kapitolu 3.8.1 (String Types) v manuálu [1].

Nechceme-li ukládat do PDF stringu jednotlivé byty nativně, máme možnost je popsat pomocí backslashe následovaném třemi oktalovými číslicemi vyjadřující hodnotu bytu. String "Cvičení je zátěž" pak může v PDF stringu být zapsaný takto:

\376\377\000C\000v\000i\001\015\000e\000n\000\355\000\040\000j\000e\000\040\000z\000\341\000t\001\033\001\176

V uvedeném příkladu vidíme nejprve byty 254, 255 zapsané oktalově, dále je oktalově zapsaná nula následovaná písmenem C (tyto dva byty reprezentují písmeno C v UTF-16 kódování). Podobně jistě dokážete dešifrovat písmena "v" a "i". Dále \001\015 je 01,0D hexadecimálně a to reprezentuje znak "č" v UNICODE. Dál si ten string dočtěte sami...

Právě takové stringy musíme generovat TEXem, pokud chceme vidět v záložkách správně napsané české a slovenské znaky. Je asi nemyslitelné, abychom psali ručně do dokumentu něco jako:

```
\pdfoutline goto name{cviceni} count0 {% záložka \string\376\string\000C\string\000v\string\000i\string\001\string\015% \string\000e\string\000n\string\000\string\000j% \string\000e\string\000\string\000\string\000o\string\000o\string\000o\string\000\string\000o\string\000o\string\001\string\001\string\016\% \pdfdest name{cviceni} xyz\relax % cíl odkazu
```

Sice je tímto způsobem na primitivní úrovni vytvořena záložka s textem "Cvičení je zátěž", ale kdybychom to takto dělali pořád, byla by to opravdu zátěž. Proto jsem vytvořil makro PDFuni, které uživatelům Csplainu ulehčí práci. Uživatelé LATEXu nic takového nepotřebují, protože mají balíček hyperref.

2 Použití balíčku PDFuni

Protože OPmac generuje do záložek texty bez akcentů, je potřeba zavolat PDFuni až po \input opmac. Balíček PDFuni předefinuje implicitní konvertor z OPmac pro výstup do PDF stringů (konvertor do ASCII) na nový konvertor do UNICODE. Takže stačí na začátku dokumentu psát:

```
\input opmac
\input pdfuni
```

Od této chvíle příkaz $\ombox{outlines}\langle num\rangle$ generuje do záložek správně české a slovenské texty. Využívá přitom automaticky generovaný obsah. OPmac nabízí ještě příkaz $\imbox{insertoutline}\{\langle text\rangle\}$, který vloží do záložek jeden údaj. Tento příkaz vkládá $\langle text\rangle$ tak jak je bez konverze, z čehož plyne, že tam české akcenty nebudou jednoduše fungovat. Je potřeba použít příkaz $\pombox{pdfunidef}\{text\rangle\}$, který je definován v balíčku PDFuni a který vloží do \mbox{makra} zkonvertovaný $\langle text\rangle$ v kódování UNICODE s oktalovými přepisy. Kategorie backslashe tam je 12 (obyčejný znak). Takže je potřeba psát:

```
\pdfunidef\tmp{Tady je český text}
\insertoutline{\tmp}
PDF dokument může obsahovat PDF stringy různě kódované. Takže funguje například i toto:
    % tento PDF string je v UNICODE:
\pdfunidef\tmp{Čeština je dřina}\insertoutline{\tmp}
    % tento PDF string je v PDFDocEncoding:
\insertoutline{Jan Hus vnesl do jazyka velkou hloupost: zavedl akcenty.}

Příkaz pdfTEXu \pdfinfo zanáší do PDF dokumentu doplňující informace, například takto:
\pdfinfo {/Author (Autor)
    /Title (Tutul)
    /Creator (csplain + OPmac)
    /Subject (clanek)
    /Keywords (klicova slova)}
```

Je potřeba vědět, že PDF stringem je zde každý údaj uzavřený do závorky, přičemž některé tyto PDF stringy mohou být kódovány podle PDFDocEncoding a jiné podle UNICODE. Takže je možné údaje zanést třeba takto:

Poznamenejme, že další informace /Producer a /ModDate vloží většinou nejlépe pdfTEX sám, nicméně uživatel je rovněž může předefinovat. Jsou-li oba údaje /CreationDate a /ModDate nevyplněny, pak oba obsahují čas vzniku PDF souboru. Jak je možné si všimnout, chcete-li /CreationDate vyplnit podle svého, je nutné dodržet formát D:YYYYMMDDhhmmss.

3 Možnost rozšíření kódovací tabulky o další znaky

Příkaz \pdfunidef konvertuje správně všechny viditelné ASCII znaky s kategoriemi 11, 12 (písmena, znaky) a dále znaky s kategoriemi 7, 8 (^, _). Ostatní viditelné ASCII znaky jiných kategorií (např. \$, &) jsou ignorovány. Chcete-li do PDF stringu dopravit znak jiné kategorie než 7, 8, 11, 12, musí mít takový znak před sebou backslash, tedy \\, \{, \}, \\$, \\$, \\, \\, \\, \\, \\, \\, \\.

Dále \pdfunidef konvertuje znaky kategorie 11 nebo 12, které nejsou ASCII, pokud jsou zahrnuty do seznamu \pdfunichars. Tento seznam implicitně obsahuje znaky Áá Ää Čč Ďď Éé Ěě Íí ĹÍ Ľľ Ňň Óó Öö Ôô Řŕ Řř Šš Ťť Úú Ûů Üü Ýý Žž. Oktalový zápis těchto znaků (tedy výstup konverze) ve stejném pořadí je uložen v seznamu \pdfunicodes. Kódy jsou tam zapisovány bez backslashů a bez první nuly a jsou odděleny od sebe příkazem \or. Podívejte se do souboru pdfuni.tex nebo do následující sekce, jak vypadají implicitní hodnoty těchto seznamů. Chcete-li rozšířit tuto konverzní tabulku, je možné použít příkaz \addto z OPmac například takto:

\addto\pdfunichars{Eë} \addto\pdfinicodes{\or00313\or00353}

Uvedený příklad rozšiřuje seznam \pdfunichars o znaky Ë, ë a dále rozšiřuje seznam \pdfunicodes o kódy \000\313 a \000\353. Na tyto kódy se budou znaky Ë, ë (v tomto pořadí) konvertovat. 1)

Příkaz \pdfunidef ještě před započetím konverze provede úplnou expanzi svého parametru $\langle text \rangle$. Před touto expanzí je vhodné předefinovat některá makra, např. \def\TeX{TeX}. Taková činnost je zanesena do seznamu \pdfunipre, který je (uvnitř skupiny) předřazen před expanzí parametru $\langle text \rangle$. Kromě speciálních expanzí maker tam jsou povelem \let\makro\relax zabezpečena makra, která expandovat v dané chvíli nechceme. Jsou to makra \ae, \P atd., která posléze vstoupí do konverze a promění se na svůj oktalový kód. Přidělení tohoto kódu se děje v seznamu \pdfunipost pomocí příkazu \odef\makro $\langle 6ciferný kód \rangle \langle mezera \rangle$. Např. příkazem \odef\ae000346 říkáme, že makro \ae se zkonvertuje na \000\346. Čtenáři doporučuji podívat se na obsahy seznamů \pdfunipre a \pdfunipost do souboru pdfuni.tex nebo do následující sekce.

Chcete-li rozšířit konverzní tabulku týkající se maker, lze to udělat pomocí \addto například takto:

\addto\pdfunipre{\let\endash\relax} \addto\pdfunipost{\odef\endash040023 }

Tento příklad přidává do tabulky údaj o konverzi makra \endash. Ve fázi expandování parametru je jeho expanze potlačena a dále se zkonvertuje na kód \040\023, což je dle UNICODE pomlka na půlčtverčík.

Kontrolní sekvence, které nejsou během expanze parametru $\langle text \rangle$ expandovány a nemají deklarován svůj kód pomocí \odef , jsou při konverzi ignorovány.

Nyní už čtenář patrně ví, proč při použití CSplainu s encTEXem funguje správně i právnický znak \S , ačkoli není uveden v seznamu \pdfunichars. EncTEX jej totiž mapuje na kontrolní sekvenci \S, takže kdykoli napíšeme \S , promění se to automaticky v \S. Znak \S je ošetřen v seznamu \pdfunipre, kde je napsáno \let\S\relax. A v seznamu \pdfunipost je definice \odef\S000247.

4 Popis interních maker a s nimi spojených triků

Makra z pdfuni.tex obsahují několik zajímavých triků. Jejich popis je určen pro pokročilé TeXisty. Soubor pdfuni.tex je kódován v UTF-8 kódování. Je nutné, aby byl přečten encTeXem nebo 16bitovou mašinou, protože chceme s jednotlivými akcentovanými znaky v TeXu pracovat jako s jedním tokenem. Proto je na začátku souboru test, zda je použita správná TeXová mašina:

 $\label{tmp#1#2} $$\left(\frac{\pi^{\#2}\leq \mathbb TEX+encTeX \ or \ 16bit\ TeX \ engine.}\right)^{\#2} $$ \operatorname{TeX+encTeX} \ or \ 16bit\ TeX \ engine.}^{\#2} $$$

Dále definujeme na začátku souboru makro \Bslash, které expanduje na backslash kategorie 12. Totéž dělá OPmac s makrem \bslash, ale OPmac hodnotu tohoto makra v různých místech mění. Zde potřebujeme mít jistotu, že to bude pořád backslash. Kromě toho potřebujeme pracovat s pomocným čítačem \tmpnum. Protože nevíme, zda je zavolán OPmac (makro PDFuni funguje i bez něj), je za předpokladu nedefinovanosti \newcount tento čítač deklarován.

 $^{^1}$) Aby uvedený příklad fungoval, musí mít znaky Ë, ë svou reprezentaci ve vnitřním kódování TEXu. To je u 16bitových TEXových mašin zařízeno automaticky. Při použití $\mathcal{C}_{\mathcal{S}}$ plainu a encTEXu je možné použít třeba \input t1code.

```
\ifx\tmpnum\undefined \csname newcount\endcsname\tmpnum \fi
          \{\code'\?='\\ \codef\Bslash\{?\}\} \}
         Následuje výpis implicitní hodnoty seznamů \pdfunichars a \pdfunicodes
         \edef\pdfunichars{\Bslash()
                     燀äČčĎď ÉéĚĕÍíĹĺ ĽľŇňÓóÖö ŌôŔŕŘřŠš ŤťÚúŮůÜü ÝýŽž
                                                                                                                                                                                                                                                                                            % \ ()
         \def\pdfunicodes {\or00134\or00050\or00051\or
                     00301\or00341\or00304\or00344\or01014\or01015\or01016\or01017\or % 燀äČčĎď
                     00311\or00351\or01032\or01033\or00315\or00355\or01071\or01072\or % ÉéĒĕĨíĹĨ
                     01075\or01076\or01107\or01110\or00323\or00363\or00326\or00366\or % LTŇňÓöÖ
                     00324\or00364\or01124\or01125\or01130\or01131\or01144\or01141\or % ŌōŔŕŘřŠš
                     01144\or01145\or00332\or00372\or01156\or01157\or00334\or00374\or % ŤťŰúŮůÜü
                     00335\or00375\or01175\or01176%
                                                                                                                                                                                                                                                                                            % ÝýŽž
         }
         Je vidět, že do seznamu jsou zařazeny i hodnoty \, (, ). Je to tím, že tyto znaky nechceme konvertovat
do podoby 000\langle znak\rangle, protože by v PDF stringu zlobily (backslash je escape prefix a kulaté závorky
ohraničují string). Je tedy bezpečnější je do PDF stringu zapsat v úplné oktalové notaci.
         Pokračuje výpis implicitní hodnoty \pdfunipre a \pdfunipost a některých speciálních kódů.
         \def\pdfunipre {\def\TeX{TeX}\def\LaTeX{LaTeX}\def^{ }\def\ { }\"
                     \let\ss\relax \let\l\relax \let\L\relax
                     \let\ae\relax \let\oe\relax \let\OE\relax
                     \let\o\relax \let\0\relax \let\i\relax \let\j\relax \let\aa\relax
                     \let\AA\relax \let\S\relax \let\P\relax \let\copyright\relax
                     \let\dots\relax \let\dag\relax \let\ddag\relax
                     \let\clqq\relax \let\frqq\relax \let\frqq\relax
                     \let\promile\relax \let\euro\relax
                     \def\\{\Bslash}\let\{\relax \let\}\relax
                     \def\string\$\def\&\{\string\&\}\def\_{\string}\def\^{\string}\
         }
         \def\pdfunipost {\odef\ss000337 \odef\l001102 \odef\L001101
                      \label{local_condition} $$ \operatorname{local_{0002067} \ local_{000247} \ local_{000266}} $$
                     \odef\copyright000251 \odef\dots040046 \odef\dag040040 \odef\ddag040041
                     \label{local_condition} $$ \operatorname{\crq}040034 \operatorname{\crq}0400253 \operatorname{\cdef}_{frq}000273 $$
                     \label{lem:condition} $$\operatorname{\operatorname{looef}} \operatorname{\operatorname{looef}} \operatorname{\operatorname{
                      \odef\#000043
         \def\pdfinitcode{\Bslash376\Bslash377}
         \def\pdfspacecode{\Bslash000\Bslash040}
         \def\pdfcircumflexcode{\Bslash000\Bslash136}
         \def\pdflowlinecode{\Bslash000\Bslash137}
Nyní přistoupíme na to hlavní, na definici makra \pdfunidef(makro)\{\langle text \rangle\}.
         \def\pdfunidef#1#2{\bgroup \def\tmpa{\noexpand#1}%
                      \pdfunipre \edef\tmp{#2}\edef\out{\pdfinitcode}%
                      \def\odef##1##2##3##4##5##6##7
                                 {\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_{\def}_
                      \def\insertbslashes ##1##2##3##4##5{\Bslash0##1##2\Bslash##3##4##5}%
                     \def\gobbletwowords ##1 ##2 {}%
                     \tmpnum=0
                     \loop
                                  \sfcode\tmpnum=0 \advance\tmpnum by1
                                  \ifnum \tmpnum<128 \repeat
                      \tmpnum=0
```

```
\expandafter \pdfunidefA \pdfunichars {}%
```

}

\pdfunidef nejprve zahájí skupinu a zapamatuje si jméno $\langle makra \rangle$, které má definovat, do \tmpa. Dále spustí \pdfunipre a expanduje parametr $\langle text \rangle$. Do pracovního makra \out bude postupně střádat výsledek konverze. Výchozí hodnota je \pdfinitcode, což je \376\377, neboli prefix UNICODE stringu. Dále je definováno pomocné makro \odef $\langle makro \rangle \langle 6 \ oktalových \ cifer \rangle \langle mezera \rangle$ poněkud trikoidním způsobem. Makro provede \def $\langle makro \rangle \{\& \langle cinnost \rangle \}$. Proč tam je ten znak & bude vysvětleno později. Činností, kterou makro provede, je přidání odpovídajících oktalových cifer do výstupního makra \out, přitom k těmto cifrám jsou přidány backslashe. Seznam \pdfunipost obsahuje jednotlivé příkazy \odef, tedy připraví makra ke konverzi.

Dále je připraveno pomocné makro \insertbslashes\(5 \) oktalových cifer\(\), které přidá šestou nulu na začátek a vloží na správné místo backslashe. Makro \gobbletwowords odstraní dvě následující slova ukončená mezerou. Budeme to potřebovat za chvíli.

V závěru této části je cyklem uloženo každému znaku s kódem menším než 128 sfkód rovný nule. Podle této hodnoty sfkódu poznáme, že znak je z dolní ASCII tabulky a bude kódován na $000\langle znak\rangle$. Ostatní znaky vyjmenované v seznamu $\mathbf{pdfunichars}$ budou mít každý svůj sfkód postupně se zvětšující od jedničky. To udělá makro $\mathbf{pdfunidefA}$, které postupně ze seznamu $\mathbf{pdfunichars}$ odlupuje jednotlivé znaky a dává jim odpovídající sfkódy.

```
\def\pdfunidefA #1{\if\relax#1\relax%
     \def\next{\let\next= }\afterassignment\pdfunidefB \expandafter\next\tmp\end
    \else \advance\tmpnum by1 \sfcode'#1=\tmpnum \expandafter \pdfunidefA
    \fi
}
```

Postupné odlupování končí, když je načten prázdný parametr (poznáme to podle \if\relax#1\relax, to se totiž sejde první \relax s druhým). V takovém případě zahájíme postupné odlupování expandovaného $\langle text \rangle$, který máme v \tmp. Konec druhého řádku ukázky po provedení \expandafter a následné expanzi \next vypadá takto:

Mezera za rovnítkem je důležitá, protože další případná mezera se pak skutečně přiřadí. Příkaz \let\next odloupne z \(\let \) první token a po přiřazení spustí \pdfunidefB.

```
\def\pdfunidefB {%
  \ifcat x\noexpand\next \pdfunidefC
  \else \ifcat.\noexpand\next \pdfunidefC
  \else \ifcat\noexpand\next \space \edef\out\not\pdfspacecode}%
  \else \ifcat^\noexpand\next \edef\out\pdfcircumflexcode}%
  \else \ifcat_\noexpand\next \edef\out\pdflowlinecode}%
  \else \ifcat_\noexpand\next \edef\out\pdflowlinecode}%
  \else \expandafter\ifx\expandafter&\next
  \fi\fi\fi\fi\fi
  \ifx\next\end \edef\next\def\tmpa\out\}\expandafter\egroup\next \else
  \def\next\let\next= \afterassignment\pdfunidefB \expandafter\next
  \fi
}
```

Makro \pdfunidefB prošetří obsah \next a podle jeho typu provede jeden krok konverze. V závěru své činnosti zavolá rekurzivně samo sebe a odloupne z $\langle expandovaného textu \rangle$ další token. To dělá pořád, dokud nenarazí na \end. V případě, že narazilo na \end, pak do \next vloží:

```
\def(makro)\{(zkonvertovaný\ výstup)\}
```

a nejprve expanduje \next pomocí \expandafter (tehdy si ještě pamatuje obsah \next) a vzápětí poté ukončí skupinu, vše tím zapomene a provede výsledek připravené expanze. Dílo je dokonáno.

Vraťme se k makru \pdfunidefB. Toto makro vyhodnotí především kategorii odloupnutého tokenu. Je-li to mezera, znak ^ nebo _, přidá do \out jejich odpovídající kód. Je-li to písmeno nebo ostatní znak, provede \pdfunidefC. Podívejme se tedy, co dělá \pdfunidefC.

```
\def\pdfunidefC {\edef\tmp{\expandafter\gobbletwowords\meaning\next}%
  \edef\out{\out\pdfunidefD}%
}
```

Makro \pdfunidefC potřebuje zpětně zjistit, jaký znak je v \next uložen. K tomu použije příkaz \meaning\next, který vypíše třeba the character B. Pomocí \gobbletwowords odstraníme dvě slova the character a v makru \tmp zbude jen B. Do \out pak přidáme výsledek expanze \pdfunidefD.

```
\def\pdfunidefD{%
  \ifnum\sfcode\expandafter'\tmp=0 \Bslash 000\tmp
  \else
    \expandafter \insertbslashes \ifcase \sfcode\expandafter'\tmp\pdfunicodes
    \else 000077\fi
  \fi
}
```

Toto makro musí pracovat jen s expandovatelnými primitivy. Nejprve $<page-header> \$ zkontroluje, zda konvertovaný znak (skrytý v $\$ má sfkód roven nula. V takovém případě expanduje na $000\langle znak\rangle$. Jinak pomocí $\$ protože tato podmínka není terminovaná, expanduje se i tělo tohoto $\$ wakru $\$ pdfunicodes. Víme, že tam je psáno

```
\cor\langle 5ciferný\ kód \rangle \cor\langle 5ciferný\ kód \rangle \cor\langle 5ciferný\ kód \rangle \dots
```

Celý \ifcase je uzavřen pomocí \else 000077\fi, což je kód otazníku. Expandafter před \ifcase způsobí, že toto \ifcase expanduje na svou odpovídající větev podle sfkódu, kde je $\langle 5ciferný kód \rangle$. Před tímto výsledkem se ovšem rozprostírá makro \insertbslashes, které do tohoto $\langle 5ciferného kódu \rangle$ doplní první nulu a backslashe.

Zajímavý trik je na řádku těsně nad řadou \fi\fi\fi\fi\fi v těle makra \pdfunidefB. Je tam řečeno \expandafter\ifx\expandafter&\next. Představme si, že \next je makro definované pomocí \odef. V takovém případě po vykonání těch dvou \expandafter dostáváme:

```
\ifx&&\\\ \cinnost\\\
```

a provede se tedy požadovaná činnost. Je-li \next cokoli jiného, není to shodné se znakem & a neprovede se nic. Je-li \next přímo znak &, neprovede se také nic.

Soubor pdfuni.tex je ukončen definicí makra z OPmac, která mění konvertor spuštěný při činnosti $\langle num \rangle$ z původní hodnoty (konverze do ASCII) na novou hodnotu (konverze pomocí pdfunidef).

```
\def\cnvhook #1#2{#2\pdfunidef\tmp\tmp} % the default convertor in OPmac is % redefined here
```

5 Reference

```
[1] http://www.adobe.com/devnet/acrobat/pdfs/pdf_reference_1-7.pdf
```

[2] http://petr.olsak.net/opmac.html